

二连杆机械臂控制算法对比研究

PID、模型自适应与 RBF 神经网络控制的理论与实践

本文档详细介绍了二连杆机械臂控制中三种主流方法的理论基础：比例-积分-微分（PID）控制、基于模型的自适应控制（MBAC）以及基于径向基函数神经网络（RBF-NN）的自适应控制。文档深入阐述了每种方法的数学模型、控制律推导和稳定性分析，并通过一个统一的 MATLAB 仿真试验平台对它们的性能进行了量化对比和分析。

1 系统动力学模型与控制目标

1.1 二连杆机械臂动力学

机械臂系统通常被建模为欧拉-拉格朗日（Euler-Lagrange）系统。对于一个 n 自由度的机械臂，其动力学方程可以表示为：

$$\mathbf{M}(\mathbf{q})\ddot{\mathbf{q}} + \mathbf{V}_m(\mathbf{q}, \dot{\mathbf{q}})\dot{\mathbf{q}} + \mathbf{G}(\mathbf{q}) + \mathbf{F}_d(\dot{\mathbf{q}}) = \boldsymbol{\tau} \quad (1)$$

其中：

- $\mathbf{q}, \dot{\mathbf{q}}, \ddot{\mathbf{q}} \in \mathbb{R}^n$ ：关节角度、速度和加速度向量。
- $\mathbf{M}(\mathbf{q}) \in \mathbb{R}^{n \times n}$ ：惯量矩阵（正定、对称）。
- $\mathbf{V}_m(\mathbf{q}, \dot{\mathbf{q}}) \in \mathbb{R}^{n \times n}$ ：科里奥利力和离心力矩阵。
- $\mathbf{G}(\mathbf{q}) \in \mathbb{R}^n$ ：重力项向量。
- $\mathbf{F}_d(\dot{\mathbf{q}}) \in \mathbb{R}^n$ ：摩擦力项向量。
- $\boldsymbol{\tau} \in \mathbb{R}^n$ ：控制力矩输入向量。

关键动力学特性：

1. **有界性**：惯量矩阵满足 $\lambda_{\min}(\mathbf{M})\mathbf{I} \leq \mathbf{M}(\mathbf{q}) \leq \lambda_{\max}(\mathbf{M})\mathbf{I}$ 。
2. **斜对称性**：矩阵 $\dot{\mathbf{M}}(\mathbf{q}) - 2\mathbf{V}_m(\mathbf{q}, \dot{\mathbf{q}})$ 是斜对称的。该性质对基于能量（Lyapunov）的稳定性分析至关重要。
3. **参数线性化（LIP）**：动力学方程可以表示为关于一组常数物理参数 $\boldsymbol{\Theta}$ 的线性形式：

$$\mathbf{M}(\mathbf{q})\ddot{\mathbf{q}} + \mathbf{V}_m(\mathbf{q}, \dot{\mathbf{q}})\dot{\mathbf{q}} + \mathbf{G}(\mathbf{q}) + \mathbf{F}_d(\dot{\mathbf{q}}) = \mathbf{Y}(\mathbf{q}, \dot{\mathbf{q}}, \ddot{\mathbf{q}})\boldsymbol{\Theta} \quad (2)$$

其中 $\mathbf{Y}$ 是回归矩阵（Regressor Matrix）。

1.2 控制目标

给定一个期望的关节轨迹 $\mathbf{q}_d(t)$ ，及其导数 $\dot{\mathbf{q}}_d(t)$ 和 $\ddot{\mathbf{q}}_d(t)$ 。控制目标是设计控制力矩 $\boldsymbol{\tau}$ ，使得实际关节角度 $\mathbf{q}(t)$ 能够精确跟踪期望轨迹。定义跟踪误差为：

$$\mathbf{e}(t) = \mathbf{q}_d(t) - \mathbf{q}(t) \quad (3)$$

目标是使 $\lim_{t \rightarrow \infty} \|\mathbf{e}(t)\| = 0$ 。

2 控制方法理论框架

本节详细介绍三种对比控制方法的理论基础。

2.1 方法一：比例-积分-微分（PID）控制

PID 控制是一种不依赖于系统精确模型的经典反馈控制方法。

控制律设计

对于多输入多输出（MIMO）的机械臂系统，通常采用解耦的 PID 控制策略。控制律为：

$$\tau(t) = \mathbf{K}_P \mathbf{e}(t) + \mathbf{K}_I \int_0^t \mathbf{e}(\tau) d\tau + \mathbf{K}_D \dot{\mathbf{e}}(t) \quad (4)$$

其中 $\mathbf{K}_P, \mathbf{K}_I, \mathbf{K}_D$ 是对角正定增益矩阵。

闭环系统分析

将控制律代入动力学方程（Eq. 1），得到闭环误差动力学：

$$\mathbf{M}(\mathbf{q})\ddot{\mathbf{e}} + (\mathbf{V}_m(\mathbf{q}, \dot{\mathbf{q}}) + \mathbf{K}_D)\dot{\mathbf{e}} + \mathbf{K}_P \mathbf{e} + \mathbf{K}_I \int \mathbf{e} d\tau = \boldsymbol{\eta}(t) \quad (5)$$

其中 $\boldsymbol{\eta}(t)$ 包含了系统动态的复杂非线性项和耦合项。

特点： PID 实现简单，通过反馈抑制不确定性。但理论上难以保证全局渐近稳定，且在高动态任务中性能受限于其固定增益结构。

2.2 方法二：基于模型的自适应控制（MBAC）

MBAC 利用了系统动力学的结构已知性（LIP 特性），但假设物理参数 $\boldsymbol{\Theta}$ 未知。通过在线估计参数 $\hat{\boldsymbol{\Theta}}(t)$ 来实现精确控制。本研究采用经典的 Slotine-Li 自适应控制算法。

控制律设计

定义滤波误差（滑模面） $r(t)$ ：

$$r(t) = \dot{\mathbf{e}}(t) + \boldsymbol{\Lambda} \mathbf{e}(t) \quad (6)$$

其中 $\boldsymbol{\Lambda}$ 是正定对角矩阵，决定了误差收敛速度。

定义参考速度 $\dot{\mathbf{q}}_r$ 和参考加速度 $\ddot{\mathbf{q}}_r$ ：

$$\dot{\mathbf{q}}_r = \dot{\mathbf{q}}_d + \boldsymbol{\Lambda} \mathbf{e}, \quad \ddot{\mathbf{q}}_r = \ddot{\mathbf{q}}_d + \boldsymbol{\Lambda} \dot{\mathbf{e}} \quad (7)$$

利用 LIP 特性，我们可以构造一个回归矩阵 $\mathbf{Y}_r(\mathbf{q}, \dot{\mathbf{q}}, \dot{\mathbf{q}}_r, \ddot{\mathbf{q}}_r)$ ，使得：

$$\mathbf{M}(\mathbf{q})\ddot{\mathbf{q}}_r + \mathbf{V}_m(\mathbf{q}, \dot{\mathbf{q}})\dot{\mathbf{q}}_r + \mathbf{G}(\mathbf{q}) + \mathbf{F}_d(\dot{\mathbf{q}}) = \mathbf{Y}_r(\cdot)\boldsymbol{\Theta} \quad (8)$$

设计控制律为：

$$\tau = \mathbf{Y}_r(\cdot)\hat{\boldsymbol{\Theta}}(t) + \mathbf{K}_D r(t) \quad (9)$$

闭环分析与自适应律推导

将控制律代入系统动力学，可以得到闭环误差动力学：

$$\mathbf{M}(\mathbf{q})\dot{r} + \mathbf{V}_m(\mathbf{q}, \dot{\mathbf{q}})r + \mathbf{K}_D r = \mathbf{Y}_r(\cdot)\tilde{\boldsymbol{\Theta}}(t) \quad (10)$$

其中 $\tilde{\boldsymbol{\Theta}}(t) = \boldsymbol{\Theta} - \hat{\boldsymbol{\Theta}}(t)$ 是参数估计误差。

构造李雅普诺夫 (Lyapunov) 函数候选：

$$V(t) = \frac{1}{2}r^T \mathbf{M}(\mathbf{q})r + \frac{1}{2}\tilde{\boldsymbol{\Theta}}^T \boldsymbol{\Gamma}^{-1} \tilde{\boldsymbol{\Theta}} \quad (11)$$

其中 $\boldsymbol{\Gamma}$ 是正定的自适应增益矩阵。

对 $V(t)$ 求导，并利用斜对称性 ($r^T(\frac{1}{2}\dot{\mathbf{M}} - \mathbf{V}_m)r = 0$)：

$$\dot{V}(t) = -r^T \mathbf{K}_D r + \tilde{\boldsymbol{\Theta}}^T (\boldsymbol{\Gamma}^{-1} \dot{\tilde{\boldsymbol{\Theta}}} + \mathbf{Y}_r^T r) \quad (12)$$

为了使 $\dot{V}(t) \leq 0$ (保证系统稳定且误差收敛)，我们选择自适应律 (参数更新律)。由于 $\dot{\tilde{\boldsymbol{\Theta}}} = -\dot{\hat{\boldsymbol{\Theta}}}$ ：

$$\dot{\hat{\boldsymbol{\Theta}}}(t) = \boldsymbol{\Gamma} \mathbf{Y}_r^T(\cdot)r(t) \quad (13)$$

特点：MBAC 理论上保证了全局渐近稳定性 ($e(t) \rightarrow 0$)。其性能依赖于系统结构模型的准确性，计算效率高。

注：控制理论推导通常基于 $e = q_d - q$ 。若采用 $e = q - q_d$ ，则控制律、回归矩阵和自适应律的形式会相应调整以确保稳定性证明依然成立。

2.3 方法三：RBF 神经网络自适应控制 (RBF-NN)

RBF-NN 控制利用神经网络的万能逼近能力来学习和补偿系统未知的非线性动态，不要求知道动力学结构。

RBF 网络模型与逼近

RBF 网络用于逼近未知的非线性函数。我们将整个逆动力学 (Eq. 8) 视为一个待逼近的函数 $f(\mathbf{x})$ ：

$$f(\mathbf{x}) = \mathbf{M}(\mathbf{q})\ddot{\mathbf{q}}_r + \mathbf{V}_m(\mathbf{q}, \dot{\mathbf{q}})\dot{\mathbf{q}}_r + \mathbf{G}(\mathbf{q}) + \mathbf{F}_d(\dot{\mathbf{q}}) \quad (14)$$

输入向量通常选择为 $\mathbf{x} = [\mathbf{q}^T, \dot{\mathbf{q}}^T, \mathbf{q}_d^T, \dot{\mathbf{q}}_d^T, \ddot{\mathbf{q}}_d^T]^T$ 。

根据万能逼近定理，存在最优权重 $\mathbf{W}^*$ 使得 $f(\mathbf{x}) = \mathbf{W}^{*T} \mathbf{H}(\mathbf{x}) + \epsilon(\mathbf{x})$ ，其中 ϵ 是逼近误差。 $\mathbf{H}(\mathbf{x})$ 是高斯基函数向量：

$$H_j(\mathbf{x}) = \exp\left(-\frac{\|\mathbf{x} - \mathbf{c}_j\|^2}{2b_j^2}\right) \quad (15)$$

控制律设计

控制律设计为：

$$\boldsymbol{\tau} = \hat{\mathbf{W}}^T \mathbf{H}(\mathbf{x}) + \mathbf{K}_D r \quad (16)$$

其中 $\hat{\mathbf{W}}$ 是网络权重的估计值。

闭环分析与权重更新律

闭环误差动力学变为：

$$\mathbf{M}(\mathbf{q})\dot{r} + \mathbf{V}_m(\mathbf{q}, \dot{\mathbf{q}})r + \mathbf{K}_D r = \tilde{\mathbf{W}}^T \mathbf{H}(\mathbf{x}) + \epsilon(\mathbf{x}) \quad (17)$$

其中 $\tilde{\mathbf{W}} = \mathbf{W}^* - \hat{\mathbf{W}}$ 是权重估计误差。

构造李雅普诺夫函数（忽略逼近误差 ϵ 以进行初步设计）：

$$V(t) = \frac{1}{2} r^T \mathbf{M}(\mathbf{q}) r + \frac{1}{2} \text{tr}(\tilde{\mathbf{W}}^T \mathbf{\Gamma}^{-1} \tilde{\mathbf{W}}) \quad (18)$$

求导并选择权重更新律以保证稳定性：

$$\dot{\tilde{\mathbf{W}}} = \mathbf{\Gamma} \mathbf{H}(\mathbf{x}) r^T \quad (19)$$

特点： RBF-NN 控制不依赖于动力学结构知识，适应性强。理论上保证了误差一致最终有界（UUB）。但其计算复杂度显著高于 PID 和 MBAC。

3 对比试验平台搭建（MATLAB 实现）

为了在学术研究中公平对比这三种方法,我们设计了一个统一的 MATLAB 仿真试验平台(ComparativeStudy_M

3.1 统一仿真环境与配置

动力学模型统一

试验采用基于 MBAC 方法中定义的参数化二连杆模型（包含惯性、科氏力和粘性摩擦，假设无重力 $\mathbf{G}(\mathbf{q}) = 0$ ）。

- 真实参数 $\mathbf{\Theta}_{\text{true}} = [p_1, p_2, p_3, F_{d1}, F_{d2}]^T = [3.473, 0.196, 0.242, 5.3, 1.1]^T$ 。

控制任务与轨迹

要求机械臂跟踪一个复杂的时变轨迹（时长 30 秒）：

$$\mathbf{q}_d(t) = \begin{bmatrix} 0.5 \sin(t) \\ 2 \cos(t/4) \end{bmatrix} \text{ rad} \quad (20)$$

初始状态设置了初始误差 $\Delta \mathbf{q}(0) = [0.1, -0.2]^T$ 以评估收敛性能。

数值求解与实现框架

仿真采用 MATLAB 的刚性求解器 **ode15s**。自适应系统通常具有”刚性”（Stiffness），即系统动态包含差异很大的时间尺度（快变的机械运动和慢变的参数适应），ode15s 能更稳定地处理此类问题。

框架采用模块化设计，通用运行器（run_simulation）根据控制器类型配置初始状态向量和相应的 ODE 函数。

3.2 控制器实现细节与参数配置

状态向量增广

根据控制器的需要，状态向量 $\mathbf{X}$ 被增广：

- PID: $X = [\mathbf{q}^T, \dot{\mathbf{q}}^T, \int \mathbf{e}^T]^T$ (6 维)
- MBAC: $X = [\mathbf{q}^T, \dot{\mathbf{q}}^T, \hat{\boldsymbol{\Theta}}^T]^T$ (9 维)
- RBF-NN: $X = [\mathbf{q}^T, \dot{\mathbf{q}}^T, \text{vec}(\hat{\mathbf{W}})^T]^T$ (本例中为 $4 + 150 \times 2 = 304$ 维)

参数配置汇总

方法	关键参数	设置值
PID	$\mathbf{K}_P, \mathbf{K}_I, \mathbf{K}_D$	diag(500), diag(100), diag(100)
MBAC	反馈增益 $\mathbf{K}_D$	diag(30)
	滤波增益 $\boldsymbol{\Lambda}$ (Alpha)	diag(10)
	自适应增益 $\boldsymbol{\Gamma}$	(详见代码, 非对角矩阵)
RBF-NN	反馈增益 $\mathbf{K}_D$	diag(50)
	滤波增益 $\boldsymbol{\Lambda}$	diag(20)
	学习率 Γ (标量)	800
	神经元数量 N	150

3.3 性能评估指标

采用均方根误差 (Root Mean Squared Error, RMSE) 作为量化评估指标, 衡量整个仿真周期内的平均跟踪精度。

$$\text{RMSE}_{\text{total}} = \sqrt{\frac{1}{T} \int_0^T \|\mathbf{e}(t)\|^2 dt} \quad (21)$$

4 仿真结果与性能分析

本节分析了三种控制器在 30 秒仿真试验中的性能表现。

4.1 性能指标对比 (RMSE)

仿真得到的 RMSE 结果如下表所示:

控制方法	总 RMSE (rad)	关节 1 RMSE (rad)	关节 2 RMSE (rad)
PID	0.01377	0.00693	0.01190
MBAC	0.01057	0.00564	0.00894
RBF-NN	0.00750	0.00401	0.00634

分析: RBF-NN 展现出最优的跟踪精度, 相比 PID 提升了约 45.6%, 相比 MBAC 提升了约 29.0%。MBAC 性能优于 PID。

4.2 轨迹跟踪与误差收敛分析

(分析基于 Figure 1 的仿真结果图)

轨迹跟踪效果

三种方法均能实现对期望轨迹的有效跟踪。但在高动态变化区域，PID 控制的滞后现象相对明显，而两种自适应控制方法展现了更好的动态响应能力。

误差范数收敛 (Log Scale)

- **收敛速度**: RBF-NN 的收敛速度最快，在约 1-2 秒内迅速将误差范数降低至稳态水平。MBAC 次之，PID 最慢。
- **稳态性能**: 在稳态阶段 ($t > 5s$)，RBF-NN 维持了最低的误差水平 (约 10^{-3} 至 10^{-4} 量级)。PID 的稳态误差最高，且呈现明显的周期性波动 (约 10^{-2} 量级)，表明其对系统周期性非线性动态的补偿能力有限。MBAC 的稳态误差介于两者之间。

4.3 控制能耗与计算成本分析

控制力矩 (Control Effort)

- 三种方法的控制力矩范数 $\|\tau(t)\|$ 均在合理范围内 ($< 150 \text{ Nm}$)，未出现饱和或高频抖振。
- PID 由于依赖高增益反馈，其力矩波动幅度相对较大。MBAC 和 RBF-NN 通过自适应补偿，控制作用相对平滑。

计算成本 (仿真耗时)

控制方法	仿真耗时 (s)
PID	0.041
MBAC	0.047
RBF-NN	0.968

分析:

- PID 和 MBAC 的计算效率极高。
- **RBF-NN 的计算成本显著高于前两者 (约 20 倍)**。这是由于其高维的状态向量 (304 维) 以及复杂的网络计算导致的。

5 结论

本研究对比了 PID、MBAC 和 RBF-NN 在二连杆机械臂轨迹跟踪任务中的性能。

1. **精度与性能**: RBF-NN 展现出最高的跟踪精度和最快的收敛速度，证明了神经网络在处理复杂非线性系统中的优势。MBAC 利用结构信息，性能优于 PID。
2. **模型依赖性**: PID 不依赖模型。MBAC 依赖于动力学结构已知。RBF-NN 理论上不依赖模型结构，适应性最强。
3. **权衡**: RBF-NN 的高性能是以显著增加的计算成本为代价的。在实际应用中，需根据精度要求、计算资源和对系统模型的了解程度，权衡选择合适的控制策略。